

OTHMANE SADIKI

DATA ENGINEER | Python · PySpark · SQL · Azure & Databricks · Microsoft Fabric · Celonis

Maroc • +212 6 75 95 83 46 • othmanesadiki6114@gmail.com • LinkedIn : [Othmane Sadiki](#) • github.com/othmanestd
[othmane-sadiki.vercel.app](#) • Disponible immédiatement

PROFIL

Data Engineer, ingénieur d'État en génie informatique (EMSI, 2026). 6 mois chez Silamir sur deux projets Data & Process Intelligence : une plateforme d'aide à la décision combinant Process Mining, Machine Learning et GenAI, et une mission de migration Spark pour un grand compte télécom. Je recherche un CDI Data Engineer.

EXPÉRIENCE PROFESSIONNELLE

Silamir | Consultant Data Engineer — Stage PFE

Février – Août 2026

Projet R&D — Analyse et optimisation des processus de gestion des sinistres par Process Mining (*assurance automobile*)

- **Conçu** une architecture **Data Lakehouse Bronze / Silver / Gold** sur **Delta Lake** et **PySpark** (données clients, sinistres, réclamations et journaux d'événements).
- **Analysé** les processus de gestion des sinistres avec **Celonis** (variantes, *rework*, goulots d'étranglement) et développé un modèle de **prédiction du churn** (**Spark MLlib** — **GBTClassifier**) interprété par **SHAP**.
- **Industrialisé** un pipeline de rétention (segmentation des clients à risque, plans d'action et emails générés via **Google Gemini**), exposé dans une application **FastAPI** + **React / Next.js** dockerisée.

Mission client — Grand compte télécom (*Process Mining et monitoring de la consommation data*)

- **Migré** les pipelines de traitement de données de SQL vers **Apache Spark 3.5 (PySpark)** : calcul distribué, temps d'exécution réduit et flux scalables.
- **Modélisé et intégré** les **event logs** d'entreprise dans **Celonis** (transformations SQL, Knowledge Models, **PQL**) pour l'optimisation des processus métiers.
- **Construit** les KPI et vues de monitoring Celonis (*Data Consumption Monitoring* — APC Health Score, taux d'utilisation) exploités au quotidien par les équipes métier.

Outils : PySpark / Apache Spark 3.5, Delta Lake, SQL, Celonis (PQL, Knowledge Models), Spark MLlib, SHAP, Google Gemini, FastAPI, React / Next.js, Power BI, Docker, Jira

ONDA | AI / Data Engineer — Stage

Juillet – Septembre 2025

- **Conçu** un pipeline **ETL Python** d'extraction, de structuration et d'ingestion de données non structurées (VoiceAgent AI via Retell.ai + GenAI) vers **MySQL**, avec structuration et normalisation automatiques des champs extraits.
- **Développé et exposé** une **REST API** servant les données d'incidents IT en temps réel aux interfaces de visualisation.
- **Automatisé** les flux de monitoring et les alertes événementielles (serveur SMTP) pour réduire le délai de détection des incidents.

Outils : Python, MySQL, REST API, GenAI (Retell.ai), SMTP, JavaScript, HTML/CSS

InsurBT | AI Engineer — Stage

Juillet – Août 2024

- **Déployé** une architecture de traitement de données en temps réel (chatbot InsurBT) avec système de monitoring et d'alertes.
- **Implémenté** un pipeline de classification **NLP** via l'API **OpenAI** (GPT-3.5) pour analyser les intentions des utilisateurs et automatiser les réponses.
- **Développé** les flux d'intégration asynchrones (TypeScript, React) entre l'interface et les modèles d'IA.

Outils : OpenAI API, TypeScript, JavaScript, React

LOGINFO | Software Engineer — Stage

Juillet – Août 2023

- **Développé** une application web de gestion des licences Sage et de suivi des abonnements clients (échéances, renouvellements), utilisée par l'équipe commerciale pour le suivi du portefeuille clients et des formations proposées.

Outils : JavaScript, HTML/CSS, SQL, MySQL

PROJETS

Fabric Analytics Platform — Plateforme analytique end-to-end sur Microsoft Fabric (projet en cours)

- Ingestion et industrialisation d'un jeu de données volumineux dans un **Lakehouse Fabric** : médaillon Bronze/Silver/Gold construit via **notebooks PySpark** et **Data Pipelines**.
- Modèle sémantique et rapport **Power BI en Direct Lake**, avec comparaison des modes Direct Lake et Import sur les temps de réponse.

Outils : Microsoft Fabric (Lakehouse, Data Pipelines, Dataflow Gen2, Notebooks), PySpark, Power BI Direct Lake

DataFlow360 — Pipeline de données temps réel (Azure & Databricks) • github.com/othmanestd

- Pipeline **streaming** de bout en bout : ingestion via **Azure Event Hubs**, traitement en **Spark Structured Streaming** puis stockage en **Delta Lake**, avec un traitement des événements en quasi temps réel.
- Architecture **Lakehouse Bronze/Silver/Gold** sur **Azure Data Lake Gen2** (partitionnement optimisé, évolution de schéma), restitution via **Synapse Serverless** et Power BI.

Outils : Azure Event Hubs, Databricks (Spark), Azure Data Lake Gen2, Synapse Analytics, Power BI, Python

StreamCDC — Réplication temps réel par Change Data Capture (projet en cours)

- Capture des changements d'une base **PostgreSQL** avec **Debezium** et diffusion via **Kafka Connect** vers **Kafka**.
- Matérialisation des flux dans une table **Apache Iceberg** requêtable (Trino / DuckDB), avec gestion de l'évolution de schéma et mesure de la latence de réplication.

Outils : Kafka, Kafka Connect, Debezium, Apache Iceberg, PostgreSQL, Trino / DuckDB, Docker

DevOps Factory — Industrialisation et CI/CD sécurisés

- Chaîne logicielle automatisée **DevSecOps** orchestrée sur **Kubernetes (RKE)** / Proxmox VE : gestion des artefacts et images (Nexus, Harbor), scan de vulnérabilités, segmentation réseau pfSense / HAProxy.

Outils : GitLab CI/CD, Jenkins, Docker, Kubernetes

COMPÉTENCES

- **Langages & traitement** : Python, PySpark, SQL avancé, Java, Bash
- **Big Data & streaming** : Apache Spark 3.5, Spark Structured Streaming, Delta Lake, Kafka, Hadoop / Hive
- **Cloud & data platforms** : Azure (Databricks, Data Lake Gen2, Synapse Analytics, Event Hubs), Microsoft Fabric
- **Orchestration & CI/CD** : Airflow, Azure DevOps, GitLab CI/CD, Jenkins, Docker, Git
- **Bases de données & modélisation** : SQL Server, MySQL, Vertica, MongoDB — modèle en étoile, faits / dimensions, SCD
- **Process Mining & BI** : Celonis (PQL, Knowledge Models, transformations), Power BI, Tableau
- **Data Science** : Spark MLlib, Scikit-learn, SHAP, prétraitement et feature engineering
- **Méthodes** : Agile / Scrum, Jira, delivery en équipe distribuée

FORMATION

Ingénieur d'État en Génie Informatique

2021 – 2026

École Marocaine des Sciences de l'Ingénieur — EMSI Casablanca

Baccalauréat Sciences Physiques-Chimie

2020 – 2021

Lycée Abdelmalek Saâdi

CERTIFICATIONS

Databricks Academy Accreditation — **Databricks Fundamentals**

Databricks Knowledge Badge — **SQL Analytics on Databricks**

Databricks Knowledge Badge — **AI/BI for Data Analysts**

En préparation : Microsoft Certified — **Fabric Data Engineer Associate (DP-700)**

LANGUES

Français : courant • **Anglais** : intermédiaire (documentation technique, échanges en équipe) • **Arabe** : langue maternelle

DISTINCTIONS

Hult Prize International — Top 50 mondial

1^{ers} prix — AI2SD 2025 (catégories Intelligent Industry et Territorial Intelligence), EMSI x AIESEC Innovate 2025, UM6P Roots & Route, ENSEM x Valbium Cluster

Autres classements — UM6P x INWI DeepFake National Challenge (Top 3), Mediterranean Smart Cities 2024 (2^e prix)